

Alumno: Juan Cañar.

Docente: Ing. Diego Quisi

Covid-19 infección en Ecuador. Modelos matemáticos y predicciones

Una comparación de modelos, lineal, polinómico, logísticos y exponenciales aplicados a la infección por el virus Covid-19

Se realiza un análisis matemático simple del crecimiento de la infección en Python y dos modelos para comprender mejor la evolución de la infección.

Se crean modelos de series temporales del número total de personas infectadas hasta la fecha (es decir, las personas realmente infectadas más las personas que han sido infectadas). Estos modelos tienen parámetros, que se estimarán por ajuste de curva.

In [2]:



```
# Importar las librerías para el análisis
import pandas as pd
import numpy as np
from datetime import datetime, timedelta
from sklearn.metrics import mean_squared_error
from scipy.optimize import curve_fit
from scipy.optimize import fsolve
from sklearn import linear_model
import matplotlib.pyplot as plt
%matplotlib inline
from xml.dom import minidom
```

In [35]:




```
# Actualizar los datos (URL)
#datos tomados de https://www.google.com/covid19/mobility/
#https://github.com/owid/covid-19-data/tree/master/public/data
#url = 'Libro1.xlsx'
url = 'owid-covid-data.csv'
df = pd.read_csv(url)
df = df.fillna(0)
df
```

Out[35]:

	iso_code	continent	location	date	total_cases	new_cases	new_cases_smoothed
0	AFG	Asia	Afghanistan	2019-12-31	0.0	0.0	0.0
1	AFG	Asia	Afghanistan	2020-01-01	0.0	0.0	0.0
2	AFG	Asia	Afghanistan	2020-01-02	0.0	0.0	0.0
3	AFG	Asia	Afghanistan	2020-01-03	0.0	0.0	0.0
4	AFG	Asia	Afghanistan	2020-01-04	0.0	0.0	0.0
...
54602	0	0	International	2020-10-31	696.0	0.0	0.0
54603	0	0	International	2020-11-01	696.0	0.0	0.0
54604	0	0	International	2020-11-02	696.0	0.0	0.0
54605	0	0	International	2020-11-03	696.0	0.0	0.0
54606	0	0	International	2020-11-04	696.0	0.0	0.0

54607 rows × 49 columns



Imprimos los resultados y agregamos el numero del dia

In [36]:



```
df = df[df['location'].isin(['Ecuador'])] #Filtro la Informacion solo para Ecuador
df = df.loc[:,['date','total_cases','iso_code']] #Selecciono las columnas de analisis
# Expresar las fechas en numero de dias desde el 01 Enero
FMT = '%Y-%m-%d'
date = df['date']
df['date'] = date.map(lambda x : (datetime.strptime(x, FMT) - datetime.strptime("2020-01-01", FMT)).days)

df
#data[~data.isin([np.nan, np.inf, -np.inf]).any(1)]
```

Out[36]:

	date	total_cases	iso_code
14568	-1	0.0	ECU
14569	0	0.0	ECU
14570	1	0.0	ECU
14571	2	0.0	ECU
14572	3	0.0	ECU
...
14873	304	167147.0	ECU
14874	305	168192.0	ECU
14875	306	169194.0	ECU
14876	307	169562.0	ECU
14877	308	170110.0	ECU

310 rows × 3 columns


In [20]:



```
df.plot(x='date', y='total_cases')
#df[~df.isin([np.nan, np.inf, -np.inf]).any(1)]
#df['Ecuador']=df['Ecuador'].fillna(0) #Reemplaza con ceros
#df = df.replace(np.nan, 1)
#df.describe()
```

Out[20]:

<matplotlib.axes._subplots.AxesSubplot at 0x1fbac4ce6c8>



Ahora podemos analizar los cuatro modelos que tomaré en el examen, que son la función lineal, polinómica, logística y la función exponencial. Cada modelo tiene tres parámetros, que se estimarán mediante un cálculo de ajuste de curva en los datos históricos.

EL modelo lineal


La regresión lineal es un algoritmo de aprendizaje supervisado que se utiliza en Machine Learning y en estadística. En su versión más sencilla, lo que haremos es «dibujar una recta» que nos indicará la tendencia de un conjunto de datos continuos.

Recordemos rápidamente la fórmula de la recta:

$$Y = mX + b$$

Donde Y es el resultado, X es la variable, m la pendiente (o coeficiente) de la recta y b la constante o también conocida como el «punto de corte con el eje Y» en la gráfica (cuando X=0) Ejemplo

The development in Pizza prices in Denmark from 2009 to 2018



Recordemos que los algoritmos de Machine Learning Supervisados, aprenden por sí mismos y -en este caso- a obtener automáticamente esa «recta» que buscamos con la tendencia de predicción. Para hacerlo se mide el error con respecto a los puntos de entrada y el valor «Y» de salida real.

In [18]:



```
x = list(df.iloc[:, 0]) # Fecha
y = list(df.iloc[:, 1]) # Numero de casos
# Creamos el objeto de Regresión Lineal
regr = linear_model.LinearRegression()
print(x)
# Entrenamos nuestro modelo
regr.fit(np.array(x).reshape(-1, 1), y)

# Veamos los coeficientes obtenidos, En nuestro caso, serán la tangente
print('Coefficients: \n', regr.coef_)
# Este es el valor donde corta el eje Y (en X=0)
print('Independent term: \n', regr.intercept_)
# Error Cuadrado Medio
```

```
[-1, 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 2
0, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33, 34, 35, 36, 37, 38, 3
9, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55, 56, 57, 5
8, 59, 60, 61, 62, 63, 64, 65, 66, 67, 68, 69, 70, 71, 72, 73, 74, 75, 76, 7
7, 78, 79, 80, 81, 82, 83, 84, 85, 86, 87, 88, 89, 90, 91, 92, 93, 94, 95, 9
6, 97, 98, 99, 100, 101, 102, 103, 104, 105, 106, 107, 108, 109, 110, 111, 1
12, 113, 114, 115, 116, 117, 118, 119, 120, 121, 122, 123, 124, 125, 126, 12
7, 128, 129, 130, 131, 132, 133, 134, 135, 136, 137, 138, 139, 140, 141, 14
2, 143, 144, 145, 146, 147, 148, 149, 150, 151, 152, 153, 154, 155, 156, 15
7, 158, 159, 160, 161, 162, 163, 164, 165, 166, 167, 168, 169, 170, 171, 17
2, 173, 174, 175, 176, 177, 178, 179, 180, 181, 182, 183, 184, 185, 186, 18
7, 188, 189, 190, 191, 192, 193, 194, 195, 196, 197, 198, 199, 200, 201, 20
2, 203, 204, 205, 206, 207, 208, 209, 210, 211, 212, 213, 214, 215, 216, 21
7, 218, 219, 220, 221, 222, 223, 224, 225, 226, 227, 228, 229, 230, 231, 23
2, 233, 234, 235, 236, 237, 238, 239, 240, 241, 242, 243, 244, 245, 246, 24
7, 248, 249, 250, 251, 252, 253, 254, 255, 256, 257, 258, 259, 260, 261, 26
2, 263, 264, 265, 266, 267, 268, 269, 270, 271, 272, 273, 274, 275, 276, 27
7, 278, 279, 280, 281, 282, 283, 284, 285, 286, 287, 288, 289, 290, 291, 29
2, 293, 294, 295, 296, 297, 298, 299, 300, 301, 302, 303, 304, 305, 306, 30
7, 308]
Coefficients:
[582.45965159]
Independent term:
-34540.86297054547
```

De la ecuación de la recta $y = mX + b$ nuestra pendiente «m» es el coeficiente y el término independiente «b»

In [6]:




```
#Vamos a comprobar:
# Quiero predecir cuántos "Casos" voy a obtener por en el día 100,
# según nuestro modelo, hacemos:
cantidad = int(input("ESCRIBA NUMERO DE DIAS: "))
y_prediccion = regr.predict([[cantidad]])
print('Para el día', cantidad, 'hay estos casos: ', int(y_prediccion))
```

```
ESCRIBA NUMERO DE DIAS: 100
Para el día 100 hay estos casos: 23705
```

In [7]:

```
#Graficar
plt.scatter(x, y)
x_real = np.array(range(0, 50))
#print(x_real)
plt.plot(x_real, regr.predict(x_real.reshape(-1, 1)), color='red')
plt.show()
```



El modelo logístico


El modelo logístico se ha utilizado ampliamente para describir el crecimiento de una población. Una infección puede describirse como el crecimiento de la población de un agente patógeno, por lo que un modelo logístico parece razonable. La expresión más genérica de una función logística es:

$$f(x, a, b, c) = \frac{c}{1 + e^{-(x-b)/a}}$$

En esta fórmula, tenemos la variable x que es el tiempo y tres parámetros: a, b, c.

- a se refiere a la velocidad de infección
- b es el día en que ocurrieron las infecciones máximas
- c es el número total de personas infectadas registradas al final de la infección

A continuación se puede apreciar un ejemplo de regresión logística



Definamos la función en Python y realicemos el procedimiento de ajuste de curva utilizado para el crecimiento logístico.

In [52]:

```
def modelo_logistico(x,a,b):
    res=0
    if x[1] == 0:
        x=1
    else:
        res= a+b*np.log(x)
    return res

exp_fit = curve_fit(modelo_logistico,x,y) #Extraemos los valores de los paramatros
print(exp_fit)
```

```
(array([1., 1.]), array([[inf, inf],
                        [inf, inf]]))
```

Graficas

In [56]:



```
pred_x = list(range(min(x),max(x)+10)) # Predecir 50 dias mas
plt.rcParams['figure.figsize'] = [7, 7]
plt.rc('font', size=14)
# Real data
plt.scatter(x,y,label="Datos Reales",color="red")
# Predicted exponential curve
plt.plot(pred_x, [modelo_logistico(i,exp_fit[0][0],exp_fit[0][1]) for i in pred_x], label="")
plt.legend()
plt.xlabel("Desde el 1 Enero 2020")
plt.ylabel("Total de personas infectadas")
plt.ylim((min(y)*0.9,max(y)*3.1)) # Definir los limites de Y
plt.show()
```

TypeError

Traceback (most recent call last)

<ipython-input-56-c624f7bdc450> in <module>

5 plt.scatter(x,y,label="Datos Reales",color="red")

6 # Predicted exponential curve

----> 7 plt.plot(pred_x, [modelo_logistico(i,exp_fit[0][0],exp_fit[0][1]) for
r i in pred_x], label="Modelo Logistico")

8 plt.legend()

9 plt.xlabel("Desde el 1 Enero 2020")

<ipython-input-56-c624f7bdc450> in <listcomp>(.0)

5 plt.scatter(x,y,label="Datos Reales",color="red")

6 # Predicted exponential curve

----> 7 plt.plot(pred_x, [modelo_logistico(i,exp_fit[0][0],exp_fit[0][1]) for
r i in pred_x], label="Modelo Logistico")

8 plt.legend()

9 plt.xlabel("Desde el 1 Enero 2020")

<ipython-input-52-d4479d0c1295> in modelo_logistico(x, a, b)

1 def modelo_logistico(x,a,b):

2 res=0


----> 3 if x[1] == 0:

4 x=1

5 else:

TypeError: 'int' object is not subscriptable






Modelo exponencial

Mientras que el modelo logístico describe un crecimiento de infección que se detendrá en el futuro, el modelo exponencial describe un crecimiento de infección imparabile . Por ejemplo, si un paciente infecta a 2 pacientes por día, después de 1 día tendremos 2 infecciones, 4 después de 2 días, 8 después de 3 y así sucesivamente.

$$f(x, a, b, c) = a \cdot e^{b(x-c)}$$

A continuacion se tiene un ejemplo de regresion exponencial

Curva de ajuste para una función tipo
exponencial $y = ae^{kx}$
usando mínimos cuadrados



In [43]:

```
def modelo_exponencial(x,a,b):
    return a+b*np.exp(b*x)

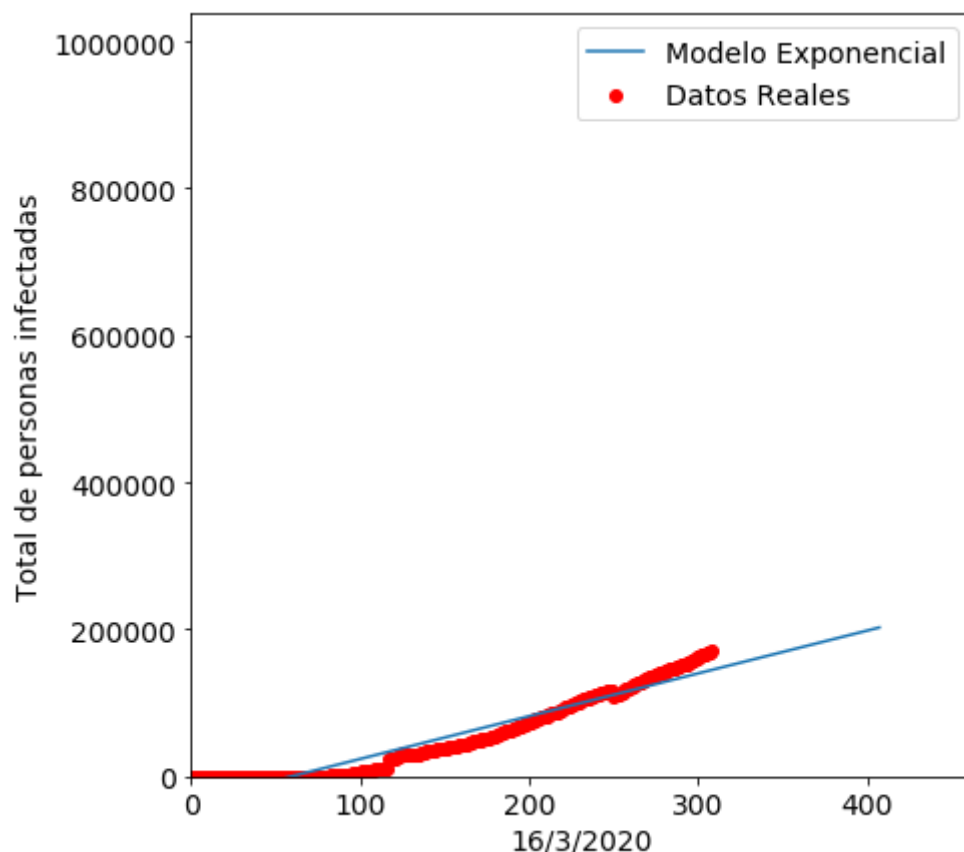
exp_fit = curve_fit(modelo_exponencial,x,y)
#print(exp_fit)

pred_x = list(range(0,max(x)+100))
plt.rcParams['figure.figsize'] = [7, 7]
plt.rc('font', size=14)

plt.scatter(x,y,label="Datos Reales",color="red")
# Predicted exponential curve
puntos=[modelo_exponencial(i,exp_fit[0][0],exp_fit[0][1]) for i in pred_x]
print ('Predicción a 7 días sumando desde el ultimo día en x(30):', puntos[37], 'contagiado')
#print(x)

plt.plot(pred_x,puntos , label="Modelo Exponencial")
plt.legend()
plt.xlabel("16/3/2020")
plt.ylabel("Total de personas infectadas")
plt.ylim((0,max(y)*6.1))
plt.xlim((min(x)*0.9,max(x)*1.5))
plt.plot(37,puntos[37], 'oy')
plt.show()
```

Predicción a 7 días sumando desde el ultimo día en x(30): -12989.85599420606
contagiados




Modelo polinomial

Predicción de una variable de respuesta cuantitativa a partir de una variable predictora cuantitativa, donde la relación se modela como una función polinomial de orden n (esto significa que pueden tener de diferentes exponenciales o grados y se debe ir probando)

Se puede tener una ecuacion con diferentes grados

$$y = a_0 + a_1x + a_2x^2 + a_3x^3 + \dots + a_nx^n + \varepsilon$$

Ejemplo de una regresion polinomica de grado 4.



Deber

In [136]:



```
# Implementar
filtro = df["Ecuador"][:] # Filtro los datos que se empezo a tener casos
#Obtenemos la mediana
print(filtro)
media = filtro.mean()
mediana = filtro.median()
print(mediana)
print(media)

#Tratar de predecir que va a pasar la proxima semana. y el prox mes.
```

```
0      0.0
1      0.0
2      0.0
3      0.0
4      0.0
...
304    1394.0
305     845.0
306    1045.0
307    1002.0
308     368.0
Name: Ecuador, Length: 309, dtype: float64
462.0
557.7697368421053
```

In [138]:




```
url = 'https://covid.ourworldindata.org/data/ecdc/total_cases.csv'
df_t = pd.read_csv(url)
df_t = df_t.replace(np.nan, 0)
FMT = '%Y-%m-%d'
date = df_t['date']
df_t['date'] = date.map(lambda x : (datetime.strptime(x, FMT) - datetime.strptime("2020-01-
df_t = df_t.loc[:,['date', 'Ecuador']] #Selecciono las columnas de analisis
y = list(df_t.iloc[:, 1]) # Total casos
x = list(df_t.iloc[:, 0]) # Dias
#Realizamos un ejemplo de prediccion
prediccion_siguiente = int(y[-1] + mediana)
```

In [140]:

```
# Quiero predecir cuántos "Casos" voy a obtener de aqui a 7 dias.
for i in range(x[-1], x[-1]+7):
    x.append(i)
    y.append(int(y[-1] + mediana))
plt.plot(x[61:], y[61:])
plt.show()

print('cuantos contagiados mas:',y[-1]+7)
```




cuantos contagiados mas: 177423

In [143]:

```
# Quiero predecir cuántos "Casos" voy a obtener de aqui a 45 dias.
for i in range(x[-1], x[-1]+45):
    x.append(i)
    y.append(int(y[-1] + mediana))
plt.plot(x[61:], y[61:])
plt.show()

print('cuantos contagiados mas:',y[-1]+45)
```



cuantos contagiados mas: 219041

Numero de infectados menos el numero de recuperados.

Estadísticas



Resultados principales



In [175]:


```
labels = ['Infectados', 'Recuperados', 'Muertos']
men_means = [170000, 149000, 12698]
x = np.arange(len(labels)) # the label locations
width = 0.35 # the width of the bars

fig, ax = plt.subplots()
rects1 = ax.bar(x - width/2, men_means, width, label='Porcentaje x cada 10000000')
#rects2 = ax.bar(x + width/2, women_means, width, label='Mujer')

# Add some text for labels, title and custom x-axis tick labels, etc.
ax.set_ylabel('cantidad')
ax.set_title('Indice de infectados')
ax.set_xticks(x)
ax.set_xticklabels(labels)
ax.legend()
```

Out[175]:

<matplotlib.legend.Legend at 0x2164f4bb908>



Analisis

- ◀ 1 ▶